TAREA M57 – CD-YAIR PALOMARES

```
import pandas as pd
import os
os.chdir("C:/Users/yair_/OneDrive/Desktop/Ciencia de Datos/Módulo 57 - Modelos ARIMA(p,d,q)")

df = pd.read_csv("TempNY.csv")
df
```

	Year	Average	Unnamed: 2
0	1870	53.60	NaN
1	1871	51.13	NaN
2	1872	50.98	NaN
3	1873	50.98	NaN
4	1874	51.34	NaN
...	...	...	...
146	2016	57.18	NaN
147	2017	56.22	NaN
148	2018	55.88	NaN
149	2019	55.62	NaN
150	2020	57.28	NaN

151 rows × 3 columns

```
df = df.drop(columns = ["Unnamed: 2"])
df.index = df["Year"]
df = df.drop("Year", axis = 1)
df
```

Year	Average
1870	53.60
1871	51.13
1872	50.98
1873	50.98
1874	51.34
...	...
2016	57.18
2017	56.22
2018	55.88
2019	55.62
2020	57.28

151 rows × 1 columns

```
# Se establecen los conjuntos para datos de entrenamiento y prueba
len_train = int(len(df) * 0.9)
len_test = len(df) - len_train
train = df[0:len_train]
test = df[len_train:]
```

```
train["Average"].plot()
```

```
<Axes: xlabel='Year'>
```

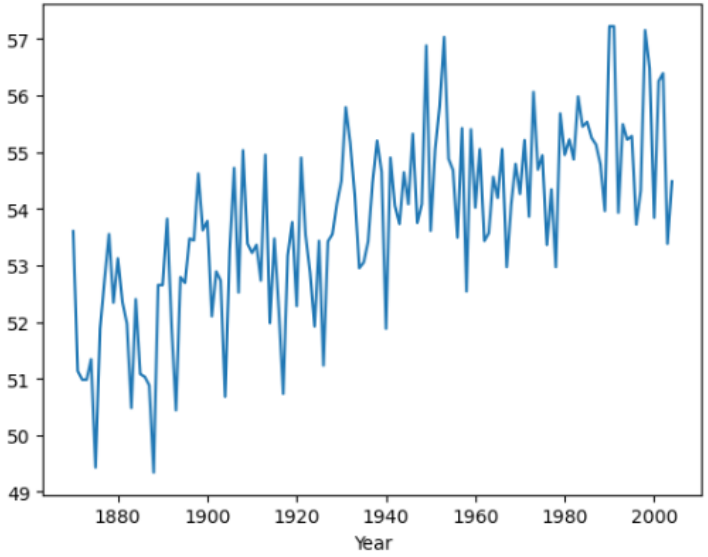

```python
#Prueba de Dickey-Fuller a datos de entrenamiento
from statsmodels.tsa.stattools import adfuller
result = adfuller(train["Average"])
print("El valor p de la prueba de Dickey-Fuller es: ", result[1])
```

```
El valor p de la prueba de Dickey-Fuller es:  0.42201206191180785
```

```python
# Se aplican primeras diferencias para buscar convertir esta serie en una serie estacionaria
train["temp_change"] = train["Average"].diff()
train = train.dropna()
```

```python
train["temp_change"].plot()
```

```
<Axes: xlabel='Year'>
```

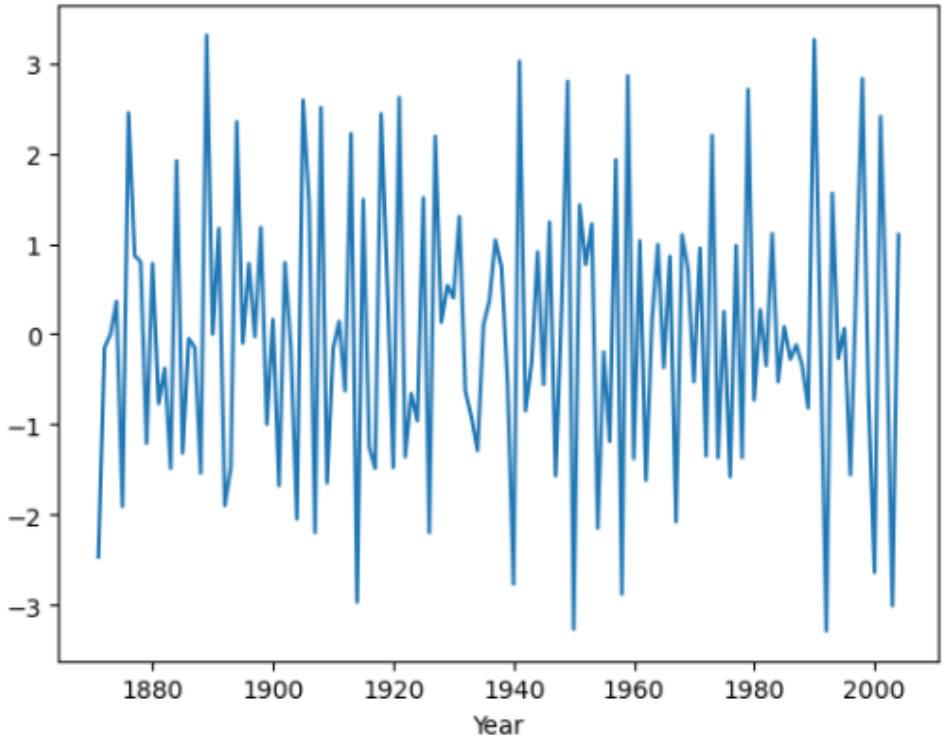


```python
# Aplicación de la prueba Dickey-Fuller sobre las diferencias calculadas en base de datos de entrenamiento
result2 = adfuller(train["temp_change"])
print("El valor p de la prueba Dickey-Fuller es: ", result2[1])
```

```
El valor p de la prueba Dickey-Fuller es:  1.5713108896118464e-13
```

Conclusión: Se divide la base de datos con el 90% de datos para entrenamiento y 10% de prueba. La prueba de Dickey-Fuller en primera instancia arroja que los datos no son estacionarios, por lo que se realizan primeras diferencias y esta conversión ya permite tener estacionariedad de acuerdo con el estadístico de Dickey-Fuller.

```
# Analizando la autocorrelación de los datos para definir los parámetros óptimos del modelo
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf

fig, axes = plt.subplots(2,1)

#Graficación de la función de autocorrelación ACF
plot_acf(train["temp_change"], lags = 20, ax = axes[0], alpha = 0.05)

#Graficación de la función de autocorrelación parcial PACF
plot_pacf(train["temp_change"], lags = 20, ax = axes[1], alpha = 0.05)

plt.show()
```

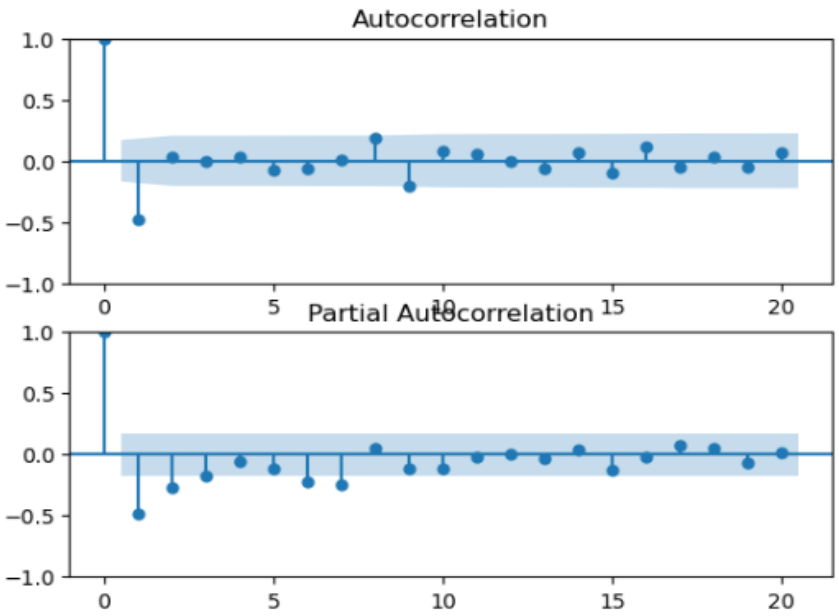

Con ayuda de la gráfica, se observa que el valor inmediato anterior en la serie, es el que mejor predice el valor actual. De igual forma, se comprueba esta conclusión realizando pruebas con diferentes valores de p en el modelo AR(p)

```python
# Importación del módulo para estimar un modelo ARIMA (primera combinación)
from statsmodels.tsa.arima.model import ARIMA

#Ajustar los datos a un modelo AR(1) e imprimir su AIC
mod_ar1 = ARIMA(train["temp_change"], order = (1,0,0))
res_ar1 = mod_ar1.fit()
print("El AIC para AR(1) es: ", res_ar1.aic)
```

```
El AIC para AR(1) es:  464.2789529854747
```

```python
#Ajustar los datos a un modelo AR(2) e imprimir su AIC (segunda combinación)
mod_ar2 = ARIMA(train["temp_change"], order = (2,0,0))
res_ar2 = mod_ar2.fit()
print("El AIC para AR(1) es: ", res_ar2.aic)
```

```
El AIC para AR(1) es:  455.4886439186555
```

```python
#Ajustar los datos a un modelo ARMA(1,1) e imprimir su AIC (tercera combinación)
mod_arma11 = ARIMA(train["temp_change"], order = (1,0,1))
res_arma11 = mod_arma11.fit()
print("El AIC para AR(1) es: ", res_arma11.aic)
```

```
El AIC para AR(1) es:  428.92693283531935
```

```python
#Ajustar los datos a un modelo ARMA(1,1) e imprimir su AIC (cuarta combinación)
mod_arma11 = ARIMA(train["temp_change"], order = (2,0,1))
res_arma11 = mod_arma11.fit()
print("El AIC para AR(1) es: ", res_arma11.aic)
```

```
El AIC para AR(1) es:  430.2016999801665
```

```python
#Ajustar los datos a un modelo ARMA(1,1) e imprimir su AIC (quinta combinación)
mod_arma11 = ARIMA(train["temp_change"], order = (2,0,2))
res_arma11 = mod_arma11.fit()
print("El AIC para AR(1) es: ", res_arma11.aic)
```

```
El AIC para AR(1) es:  430.2840584606017
```

```python
#Ajustar los datos a un modelo ARMA(1,1) e imprimir su AIC (sexta combinación)
mod_arma11 = ARIMA(train["temp_change"], order = (2,0,3))
res_arma11 = mod_arma11.fit()
print("El AIC para AR(1) es: ", res_arma11.aic)
```

```
El AIC para AR(1) es:  428.46354657435023
```

Conclusión: La serie de tiempo original de temperaturas se modela bien con ARIMA(1,1,1), ya que es el modelo que arroja mejor estadistico de Akaike

Conclusión: Se realizan 6 diferentes combinaciones del modelo ARIMA(p,d,q) para determinar cuál sería el de mejor ajuste, esto de acuerdo con el valor del estadístico Akaike. Los de mejor performance fueron los de (1,1,1) y (2,1,3). Una vez realizando el modelo con ambas opciones, el mejor resultado fue con la combinación (1,1,1).

```
df = pd.read_csv("TempNY.csv")
df = df.drop(columns = ["Unnamed: 2"])
df.index = df["Year"]
df = df.drop("Year", axis = 1)
df
```

Year	Average
1870	53.60
1871	51.13
1872	50.98
1873	50.98
1874	51.34
...	...
2016	57.18
2017	56.22
2018	55.88
2019	55.62
2020	57.28

151 rows × 1 columns

```
#Importación del módulo ARIMA de statsmodels
from statsmodels.tsa.arima.model import ARIMA
from statsmodels.graphics.tsaplots import plot_predict

#Pronóstico de temperaturas usando un modelo ARIMA(1,1,1)
mod = ARIMA(df["Average"], order = (1,1,1))
res = mod.fit()

print(res.summary())
```

```
==============================================================================
Dep. Variable:                Average   No. Observations:                  151
Model:                 ARIMA(1, 1, 1)   Log Likelihood                -238.826
Date:                Tue, 07 Apr 2026   AIC                            483.652
Time:                        16:20:28   BIC                            492.683
Sample:                             0   HQIC                           487.321
                                - 151
Covariance Type:                  opg
==============================================================================
                 coef    std err          z      P>|z|      [0.025      0.975]
------------------------------------------------------------------------------
ar.L1          0.0646      0.109      0.590      0.555      -0.150       0.279
ma.L1         -0.8669      0.057    -15.261      0.000      -0.978      -0.756
sigma2         1.4020      0.199      7.043      0.000       1.012       1.792
===================================================================================
Ljung-Box (L1) (Q):                   0.04   Jarque-Bera (JB):                 2.89
Prob(Q):                              0.84   Prob(JB):                         0.24
Heteroskedasticity (H):               0.83   Skew:                            -0.16
Prob(H) (two-sided):                  0.51   Kurtosis:                         2.40
===================================================================================

Warnings:
[1] Covariance matrix calculated using the outer product of gradients (complex-step).
```

```python
# Se realizan las predicciones de la base de prueba
predicciones = res.forecast(len(test))

test = pd.DataFrame(test)
predicciones = pd.DataFrame(predicciones)
test = test.reset_index()
predicciones = predicciones.reset_index()
```

```python
import numpy as np

acumulador1 = 0
acumulador2 = 0

for contador in range(0,len_test):
    acumulador1 = acumulador1 + (test.iloc[contador,1] - predicciones.iloc[contador,1]) ** 2
    acumulador2 = acumulador2 + np.abs((test.iloc[contador,1] - predicciones.iloc[contador,1]) / test.iloc[contador,1])

mse = acumulador1 / len_test
rmse = np.round(np.sqrt(mse), 2)
mape = np.round((acumulador2 / len_test) * 100, 2)
print("RMSE = ", rmse, "MAPE = ", mape)
```

```
RMSE =  0.98 MAPE =  1.5
```

Conclusión: El modelo ARIMA(1,1,1) arroja un valor estadístico de Akaike de 483.652. Sus predicciones tienen un promedio de error de 0.98 grados, representando un 1.5% del valor de la temperatura.

```
#Intervalos de confianza para las predicciones con alpha de 5%
conf = res.get_forecast(len_test).conf_int(alpha = 0.05)
conf
```

	lower Average	upper Average
151	53.829710	58.471183
152	53.711871	58.443137
153	53.683071	58.462516
154	53.659995	58.484984
155	53.637485	58.507455
156	53.615203	58.529735
157	53.593122	58.551815
158	53.571237	58.573700
159	53.549541	58.595396
160	53.528031	58.616906
161	53.506701	58.638236
162	53.485546	58.659391
163	53.464564	58.680373
164	53.443748	58.701189
165	53.423097	58.721840
166	53.402605	58.742332

```python
#Para acomodar las fechas como index en todos los data frames y graficar
lista = test["Year"]
lista = pd.DataFrame(lista)
predicciones.drop(columns = ["index"], inplace = True)
frames = [lista, predicciones]
result = pd.concat(frames, axis = 1, join = "inner")
result.columns = ["Year", "Predicciones"]
result
```

	Year	Predicciones
0	2005	56.150446
1	2006	56.077504
2	2007	56.072794
3	2008	56.072490
4	2009	56.072470
5	2010	56.072469
6	2011	56.072469
7	2012	56.072469
8	2013	56.072469
9	2014	56.072469
10	2015	56.072469
11	2016	56.072469
12	2017	56.072469
13	2018	56.072469
14	2019	56.072469
15	2020	56.072469

```python
conf = conf.reset_index()
conf.drop(columns = ["index"], inplace = True)
conf
```

	lower Average	upper Average
0	53.829710	58.471183
1	53.711871	58.443137
2	53.683071	58.462516
3	53.659995	58.484984
4	53.637485	58.507455
5	53.615203	58.529735
6	53.593122	58.551815
7	53.571237	58.573700
8	53.549541	58.595396
9	53.528031	58.616906
10	53.506701	58.638236
11	53.485546	58.659391
12	53.464564	58.680373
13	53.443748	58.701189
14	53.423097	58.721840
15	53.402605	58.742332

```
frames = [lista, conf]
intervalos = pd.concat(frames, axis = 1, join = "inner")
intervalos
```

	Year	lower Average	upper Average
0	2005	53.829710	58.471183
1	2006	53.711871	58.443137
2	2007	53.683071	58.462516
3	2008	53.659995	58.484984
4	2009	53.637485	58.507455
5	2010	53.615203	58.529735
6	2011	53.593122	58.551815
7	2012	53.571237	58.573700
8	2013	53.549541	58.595396
9	2014	53.528031	58.616906
10	2015	53.506701	58.638236
11	2016	53.485546	58.659391
12	2017	53.464564	58.680373
13	2018	53.443748	58.701189
14	2019	53.423097	58.721840
15	2020	53.402605	58.742332

```
test.index = test["Year"]
test.drop(columns = ["Year"], inplace = True)
result.index = result["Year"]
result.drop(columns = ["Year"], inplace = True)
intervalos.index = intervalos["Year"]
intervalos.drop(columns = ["Year"], inplace = True)
```
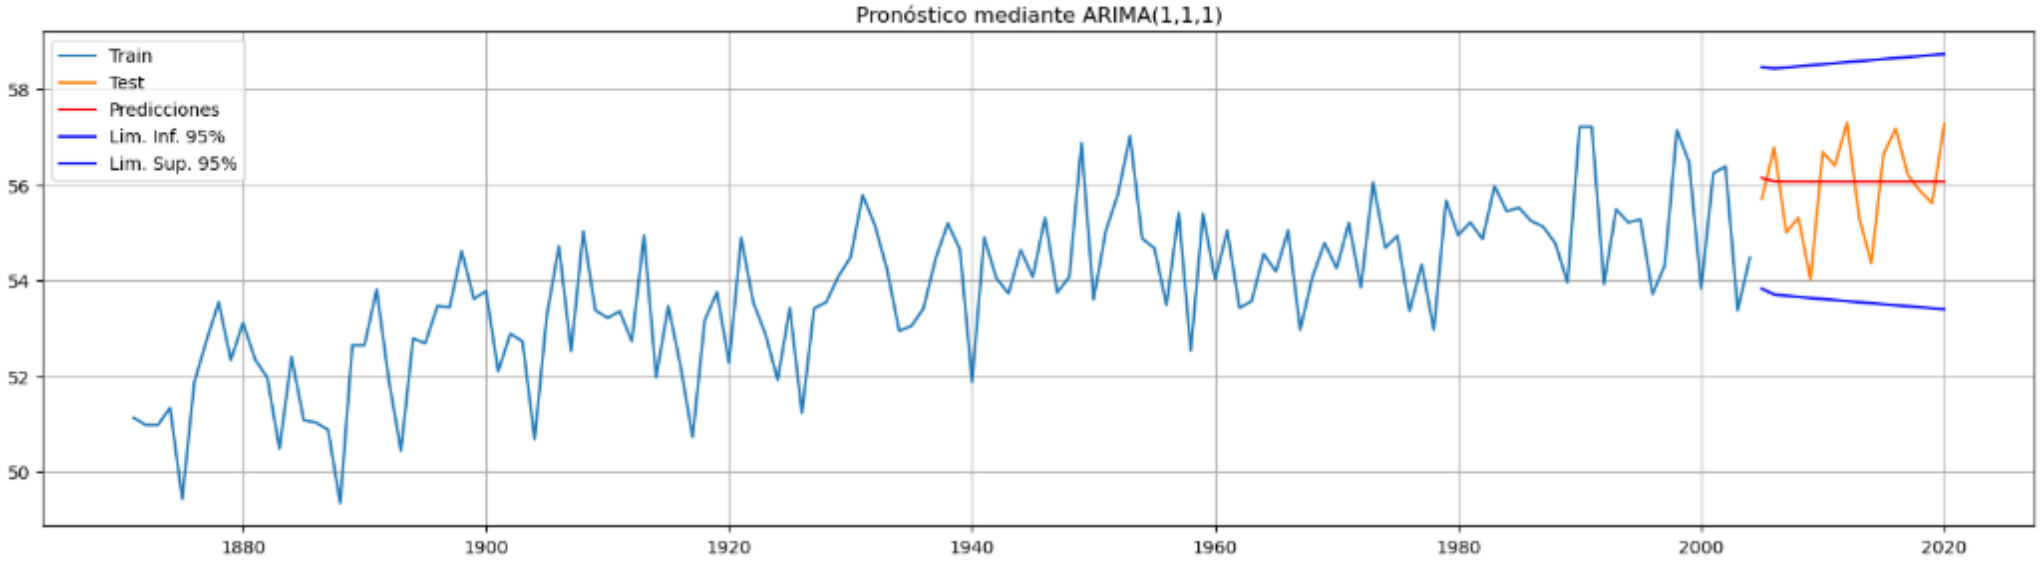
```python
plt.figure(figsize = (20,5))
plt.grid()
plt.plot(train["Average"], label = "Train")
plt.plot(test, label = "Test")
plt.plot(result, label = "Predicciones", color = "red")
plt.plot(intervalos["lower Average"], label = "Lim. Inf. 95%", color = "blue")
plt.plot(intervalos["upper Average"], label = "Lim. Sup. 95%", color = "blue")
plt.legend(loc = "best")
plt.title("Pronóstico mediante ARIMA(1,1,1)")
plt.show()
```